



Extended Kalman Filter using Normalizing Flow and Variational Inference

علی ایزدی

تیر ۱۴۰۰

فهرست مطالب

2	فهرست مطالب
3	۱- مقدمه
4	۲- مرور VAE و variational inference with normalizing flow
4	۱-۱- variational autoencoder
5	۱-۲- variational inference with normalizing flow
6	۳- Deep kalman filter
6	۳-۱- Encoder or inference model or recognition model
7	۳-۲- Decoder or generative model
8	۴- روش پیشنهادی
9	۵- مروری بر کارهای گذشته
11	مراجع

۱- مقدمه

در [قسمت ۲](#) ابتدا به طور مختصر به بررسی مقالات [variational autoencoder](#) و سپس [variational inference with normalizing flow](#) خواهیم پرداخت.

در [قسمت ۳](#) نیز به توضیح [deep kalman filter](#) که روشی برای extended kalman filter بوده و از VAE برای حل این مسئله استفاده کرده است، خواهیم پرداخت.


همان گونه که مقاله normalizing flow توانسته است برای توزیع احتمال پسین در ساختار VAE از normalizing flow استفاده کند و توزیع احتمال پسین دقیق تر برسد، می توان از این روش استفاده کرد و برای حل مسئله extended kalman filter از normalizing flow در ساختار variational inference استفاده کرد. در [قسمت ۴](#) به این موضوع خواهیم پرداخت.

در [قسمت ۵](#) نیز مقاله [normalizing kalman filter](#) با این روش مقایسه شده است.

۲- مرور VAE و variational inference with normalizing flow

۱-۱- variational autoencoder

همان طور که میدانیم که ساختار آن مطابق [شکل ۱](#) است.



شکل ۱- variational autoencoder


در VAE هدف بهینه سازی [رابطه ۱](#) که یک lower bound برای likelihood بوده، است.

[۱]

$$F(x) = E_{q_\phi(z|x)}[\log p_\theta(x|z)] + D_{KL}[q_\phi(x|z)||p(z)]$$

۲-۱- variational inference with normalizing flow

همان طور که میدانیم ساختار آن مشابه با variational inference با استفاده از VAE است با این تفاوت که توزیع احتمال پسین q توسط normalizing flow مدل میشود. ساختار این مدل مشابه با [شکل ۲](#) است.



شکل ۲- variational inference with normalizing flow

همچنین در این حالت lower bound مطابق با [عبارت ۲](#) به دست می آید.

[۲]

$$\begin{aligned}
 F(x) &= E_{q_\phi(z|x)}[\log p_\theta(x|z)] + D_{KL}[q_\phi(x|z)||p(z)] \\
 &= E_{q_\phi(z|x)}[\log q_\phi(x|z) - \log p_\theta(x, z)] \\
 &= E_{q_0(z_0)}[\log q_k(z_k) - \log p_\theta(x, z_k)] \\
 &= E_{q_0(z_0)}[\log q_0(z_0)] - E_{q_0(z_0)}[\log p_\theta(x, z_k)] - E_{q_0(z_0)}\left[\sum_{i=1}^k \log \left| \det \frac{\delta f_i}{\delta z_{i-1}} \right| \right] \\
 &= E_{q_0(z_0)}[\log p_\theta(x|z_k)] + E_{q_0(z_0)}[\log q_0(z_0) - \log p_\theta(z_k)] - E_{q_0(z_0)}\left[\sum_{i=1}^k \log \left| \det \frac{\delta f_i}{\delta z_{i-1}} \right| \right]
 \end{aligned}$$

۳- Deep kalman filter

مقاله [deep kalman filter](#) با استفاده از ایده VAE روشی برای extended kalman filter ارائه داده است.

روابط Gaussian state space model در زیر آورده شده است.

[۳]

$$z_t \sim \mathcal{N}(G_\alpha(z_{t-1}, \Delta_t), S_\beta(z_{t-1}, \Delta_t)) \quad (Transition) \quad (1)$$

$$x_t \sim \Pi(F_\kappa(z_t)) \quad (Emission) \quad (2)$$

چون توزیع احتمال پسین $p(z|x)$ در این حالت محاسبه آن intractable بوده مقاله از روش variational inference برای تقریب این توزیع با استفاده از ساختار VAE و تخمین $q(z|x)$ به عنوان Encoder استفاده کرده است.

در ادامه ساختار Encoder و Decoder این مدل توضیح داده شده است.

۳-۱- Encoder or inference model or recognition model

Encoder میانگین و کواریانس z را در $q(z|x)$ تخمین میزند (که به خودی خود تخمین خوبی برای $p(z|x)$ نیست پس همان طور که در قسمت های بعدی توضیح داده خواهد شد میتوان از normalizing flow برای $q(z|x)$ استفاده کرد).

چون هدف حل مسئله **state space** است، پس باید این میانگین و کواریانس برای توزیع $q(z|x)$ وابسته به زمان و $z(t-1)$ باشد.

روابط محاسبه این میانگین و کواریانس در زیر آمده است. در رابطه های پایین $h(t)$ با استفاده از RNN به دست می آید.

$$h_{\text{combined}} = \frac{1}{2}(\tanh(Wz_{t-1} + b) + h_t^{\text{right}})$$

(Posterior Means and Covariances)

$$\mu_t = W_{\mu} h_{\text{combined}} + b_{\mu}$$

$$\sigma_t^2 = \text{softplus}(W_{\sigma^2} h_{\text{combined}} + b_{\sigma^2})$$

۲-۳- **Decoder** or generative model

همان طور که در [روابط state space model](#) مشاهده میشود مدل generative شامل توابع G و S و F که G و S مربوط به state transition و F مربوط به emission بین state و observation است. این توابع را میتوان با استفاده از MLP پیاده سازی کرد.

روابط G و S که برای محاسبه میانگین و کواریانس $z(t)$ در [روابط state space model](#) استفاده میشود در زیر آمده است. نکته مهم در روابط زیر وابستگی $z(t)$ به $z(t-1)$ به صورت غیر خطی است.

$$g_t = \text{MLP}(z_{t-1}, \text{ReLU}, \text{sigmoid}) \text{ (Gating Unit)}$$

$$h_t = \text{MLP}(z_{t-1}, \text{ReLU}, \mathbb{I}) \text{ (Proposed mean)}$$

(Transition Mean G_{α} and S_{β})

$$\mu_t(z_{t-1}) = (1 - g_t) \odot (W_{\mu_p} z_{t-1} + b_{\mu_p}) + g_t \odot h_t$$

$$\sigma_t^2(z_{t-1}) = \text{softplus}(W_{\sigma_p^2} \text{ReLU}(h_t) + b_{\sigma_p^2})$$

حال زمانی که $z(t)$ با استفاده از روابط بالا به دست آمد میتوان $x(t)$ را با استفاده از تابع F به دست آورد. تابع F نیز با استفاده از یک MLP مطابق با روابط زیر پیاده سازی شده است.

$$F_{\kappa}(z_t) = (W_{\text{emission}} \text{MLP}(z_t, \text{ReLU}, \text{ReLU}) + b_{\text{emission}})$$

در نتیجه با مشخص شدن ساختار encoder و decoder مدل بالا مطابق با ساختار variational autoencoder در [شکل ۱](#) و هم چنین بهینه سازی lower bound مطابق با [رابطه ۱](#) به مسئله روشی برای extended kalman filter ارائه میدهد.

مشکل روش بالا در ساده بودن توزیع احتمال پسین $q(z|x)$ است که تخمین دقیقی از توزیع احتمال پسین $p(z|x)$ نیست به خصوص که در [این مقاله](#) ماتریس کواریانس به صورت قطری در نظر گرفته شده است.

۴- روش پیشنهادی

همان طور که در قسمت قبل توضیح داده شد توزیع احتمال پسین $q(z|x)$ با در نظر گرفتن یک توزیع گوسی ساده z تخمین دقیقی برای $p(z|x)$ نیست.

یک روش برای حل این مشکل همان گونه که در [قسمت ۲](#) توضیح داده شد. استفاده از مقاله [variational inference with normalizing flow](#) برای تخمین دقیق تر این توزیع احتمال پسین با استفاده از normalizing flow است.

بنابراین روش پیشنهادی جدید شامل اضافه کردن normalizing flow به مدل deep kalman filter است.

۵- مروری بر کارهای گذشته


مقاله [normalizing kalman filter](#) برای تابع F یعنی تابع emission روش استفاده از normalizing flow را ارائه داده است.

$$\mathbf{l}_1 \sim \mathcal{N}(\mu_1, \Sigma_1) \quad (\text{initial state})$$

$$\text{(NKF model)} \quad \mathbf{l}_t = F_t \mathbf{l}_{t-1} + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, \Sigma_t), \quad (\text{transition dynamics})$$

$$\mathbf{y}_t = f_t(A_t^T \mathbf{l}_t + \epsilon_t), \quad \epsilon_t \sim \mathcal{N}(0, \Gamma_t). \quad (\text{observation model})$$

در نتیجه ساختار آن مشابه با [شکل ۳](#) است.



شکل ۳- observation های y با استفاده از معکوس تابع f توسط یک normalizing flow به z تبدیل شده اند.

در این روش اثبات میشود که

$$p(l_t | y_{1:t}; \Theta, \Lambda) = p_{\text{LGM}}(l_t | z_{1:t}; \Theta)$$

$$\ell(\Theta, \Lambda) = p(y_{1:T}; \Theta, \Lambda) = \prod_{t=1}^T p_{\text{LGM}}(z_t | z_{1:t-1}; \Theta) |\det [\text{Jac}_{z_t}(f_t)]|^{-1}$$

در نتیجه برای تخمین پارامترها با استفاده از **likelihood** و حل مسئله فیلترینگ فرم بسته وجود دارد. همان طور که در **kalman filter** خطی نیز فرم بسته وجود دارد.

در نتیجه در مقایسه با روش پیشنهادی ما در موارد زیر تفاوت وجود دارد:

- تابع **state transition** در روش پیشنهادی ما غیر خطی بوده در صورتی که در این مقاله خطی بوده و تنها ماتریس های تابع خطی آن توسط یک **RNN** تخمین زده میشود که همچنان **state transition** خطی میماند.
 - روش پیشنهادی ما **lower bound** را بهینه میکند در صورتی که این مقاله **likelihood** را به صورت مستقیم بهینه میکند. البته در روش پیشنهادی ما چون از **normalizing flow** استفاده میشود یک **lower bound** را **tight** میکند.
 - اگر به صورت دقیق تر ساختار **VAE** مدل پیشنهادی ما و ساختار **generative** این مقاله را مقایسه کنیم:
- در مدل پیشنهادی ما **normalizing flow** به $q(z|x)$ اعمال میشود و سپس **decoder** از این توزیع، $p(x|z)$ یا **observation**ها را تولید میکند.
- اما در مقاله بالا **normalizing flow** مستقیماً به $p(x|z)$ اعمال میشود.
- پس آیا میتوان نتیجه گرفت **normalizing flow** در هر دو مدل به پیچیده تر کردن تابع **emission** یا $p(x|z)$ کمک میکند؟
- اما همچنان تفاوت روش پیشنهادی در غیر خطی کردن تابع **state transition** با روش این مقاله وجود دارد که میتواند باعث بهبود مدل شود.

- [1] Kingma, D.P. and Welling, M., 2013. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- [2] Rezende, D. and Mohamed, S., 2015, June. Variational inference with normalizing flows. In *International Conference on Machine Learning* (pp. 1530-1538). PMLR.
- [3] Krishnan, R., Shalit, U. and Sontag, D., 2017, February. Structured inference networks for nonlinear state space models. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 31, No. 1).
- [4] de Bézenac, E., Rangapuram, S.S., Benidis, K., Bohlke-Schneider, M., Kurl, R., Stella, L., Hasson, H., Gallinari, P. and Januschowski, T., 2020. Normalizing Kalman Filters for Multivariate Time Series Analysis. *Advances in Neural Information Processing Systems*, 33.